

המכללה האקדמית של עמק יזרעאל
החוג למערכות מידע

EVALUATION REPORT

פרויקט גמר

חיזוי רמת חומרת פגיעה בתאונות דרכים

שם הסטודנטיות:

מאי יוסף 318608072
אלמוג יבדייב 305325417

שם המנחה:

יואב זיו

תוכן עניינים

1. הערכת התוצאות 3
2. סקירה של תהליך העבודה 7



1. הערכת התוצאות

מטרת שלב ההערכה בפרויקט היא לבחון את איכותם של המודלים שפיתחנו ולוודא שהם נותנים מענה מדויק לבעיה העסקית שהוגדרה בתחילת הפרויקט: הן בטווח הקצר (שיפור תגובת שירותי החירום והקצאת משאבים בזמן אמת) והן בטווח הארוך (תובנות לשיפור תשתיות, הגברת אכיפה). המטרה הראשונית של הפרויקט הייתה לפתח מודל שיאפשר חיזוי מדויק של רמת הפציעות בתאונות דרכים, תוך הבחנה בין דרגות חומרה שונות. במהלך הפרויקט ניסינו מספר גישות שענו לדרישה זו, אך לא הצלחנו להגיע לתוצאות מספקות בשל חוסר איזון חמור בנתונים, במיוחד עבור פציעות חמורות, תוצאות המודלים היו לא מספקות.

הגישות שנסו לחיזוי חומרת הפציעה: חיזוי רב-קטגורי, חיזוי רב-שלבי, וחיזוי בינארי. לאחר ניתוח היתרונות והחסרונות של כל אחת מהן, בעיקר הקושי בהגעה לרמת recall מספקת בקטגוריה של פציעות חמורות, הוחלט להתמקד בחיזוי בינארי (פציעה / אין פציעה), אשר הוכיח את עצמו כגישת יתר יציבה וממוקדת מטרה-מודל זה סיפק תוצאות גבוהות ואיזון מוצלח בין recall גבוה לפציעות לבין דיוק סביר, כלומר מיקוד במטרה הקריטית ביותר שהיא לא לפספס מקרים של פציעה, מתוך הבנה שכך ניתן להבטיח שגם הפציעות החמורות לא יפוספסו, גם אם הדבר יוביל לעלייה בכמות ההתראות השווא.

למרות הפשטה זו, החיזוי הבינארי תואם למטרה המרכזית של המערכת, לספק התרעה ולהצביע על תאונות המחייבות תגובה רפואית. בנוסף, נבחנו דרכים יצירתיות להשלמת התמונה, כמו בניית מפת חום המציגה אזורים עם ריבוי תאונות. כך, תוצרי המערכת יכולים לשמש גם לתכנון ארוך טווח כמו שימוש במפת החום עבור תיעוד שיפור תשתיות, לצד תמיכה בהחלטות בזמן אמת.

בשלב זה, נוסו ארבעה מודלים: CatBoost, XGBoost, LightGBM ו-Random Forest. לצורך הערכתם השתמשנו במדדים Accuracy, Precision, Recall ו-F1 Score לכל מחלקה, תוך דגש מיוחד על Recall למחלקת 'Injury' מתוך מטרה לזהות ככל האפשר מקרים של פציעה (גם על חשבון שגיאות מסוג false positive).

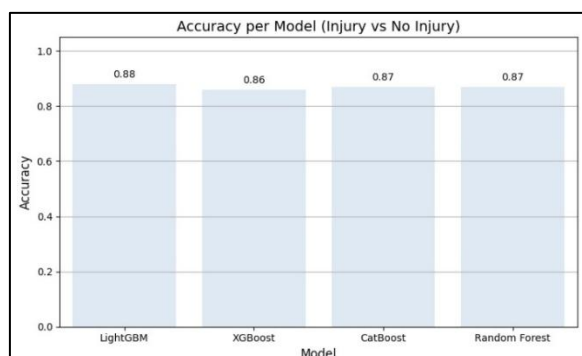
תוצאות המודלים הוצגו בצורה ויזואלית ומדידה, באמצעות טבלאות ביצועים, מטריצות בלבול וגרפים ברורים, המאפשרים לגורמים העסקיים להבין את המשמעות התפעולית של כל מודל.

להלן השוואה בין ביצועי המודלים העיקריים (CatBoost, XGBoost, LightGBM ו-Random Forest) בחיזוי בינארי, כפי שמוצג בטבלה ובגרפים להלן:

טבלה מסכמת של כל התוצאות:

CatBoost			Random Forest			XGBoost			LightGBM			Label Description
Precision	Recall	F1-Score	Precision	Recall	F1-Score	Precision	Recall	F1-Score	Precision	Recall	F1-Score	
0.99	0.85	0.92	0.98	0.85	0.91	0.99	0.84	0.91	0.99	0.86	0.92	no injury
0.59	0.96	0.73	0.58	0.94	0.71	0.57	0.97	0.72	0.6	0.95	0.74	Injury
	0.87			0.87			0.86			0.88		accuracy
0.79	0.91	0.82	0.78	0.89	0.81	0.78	0.91	0.81	0.8	0.91	0.83	macro avg
0.92	0.87	0.88	0.91	0.87	0.88	0.92	0.86	0.87	0.92	0.88	0.89	weighted avg

גרף 1: דיוק כללי (Accuracy):



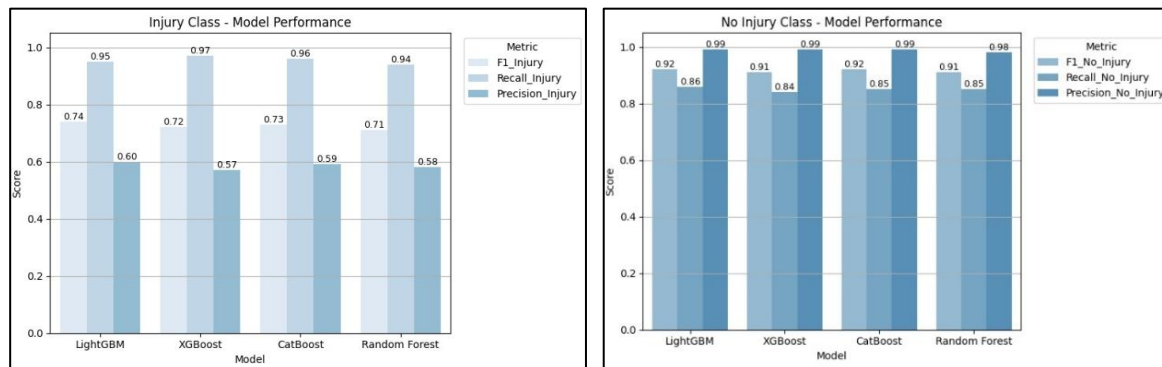
הגרף מציג את מדד ה-Accuracy עבור כל אחד מהמודלים שנבחנו בחיזוי בינארי של "פציעה / אין פציעה". כלל המודלים הציגו דיוק כללי גבוה (86%-88%), כאשר LightGBM הגיע ל-88% דיוק.

עם זאת, חשוב להדגיש כי מדד זה לבדו אינו מספק תמונה שלמה במקרים של חוסר איזון בין המחלקות. כמו בדאטה שלנו, שבו שיעור התאונות ללא פציעה גבוה בהרבה משיעור התאונות עם פציעה. במצבים כאלה, גם מודל שמנבא את רוב הדוגמאות כ"אין פציעה" עשוי להגיע לאחוז דיוק גבוה, אך לא לזהות מקרים קריטיים של פציעה ובפועל לא יתרום למטרות העסקיות שלנו.

לכן, על אף שמדד ה-Accuracy מציג תמונה כללית חיובית, הוא אינו המדד המרכזי שעל פיו נבחן את איכות המודל. ישנה חשיבות גבוהה יותר למדדים רגישים יותר לאיזון בין המחלקות, כגון Recall, Precision ו-F1-score, ובעיקר למחלקת הפציעות. מדדים אלה יוצגו בגרפים הבאים, על מנת לוודא שהמודל לא רק מדויק אלא גם מזהה באופן אפקטיבי מקרים של פציעה, מבלי להתריע יתר על המידה.



גרף 2: מדדי Precision, Recall ו-F1 Score (גרף ימני ל-No Injury, וגרף שמאלי ל-Injury)



הגרפים הבאים מציגים את ביצועי המודלים שנבחנו: CatBoost, XGBoost, LightGBM ו-Random Forest עבור שתי קטגוריות החיזוי: "יש פציעה" / "אין פציעה". הביצועים נבחנו באמצעות שלושה מדדים עיקריים: Precision, Recall ו-F1 Score, כאשר הדגש המרכזי ניתן לקטגוריית "יש פציעה", בהתאם ליעדים התפעוליים והעסקיים שהוגדרו בתחילת הפרויקט, בראשם: שיפור המענה של שירותי החירום והפחתת פספוס של פצועים בשטח.

קטגוריית "יש פציעה" - Injury Class (גרף שמאלי)

עבור קטגוריית הפציעה, כל המודלים הציגו ערכי Recall גבוהים במיוחד (0.94 ומעלה), מה שמעיד על יכולת מרשימה לזהות את מרבית המקרים בהם קיימת פציעה. מודל XGBoost הוביל עם Recall של 0.97, ואחריו CatBoost עם 0.96, ו-LightGBM עם 0.95 ו-Random Forest עם 0.94. תוצאה זו משקפת הצלחה משמעותית במניעת פספוס של פצועים, ובהשגת המטרה העסקית של זיהוי מרבי של פצועים, אלמנט קריטי לקבלת החלטות בשטח והקצאת משאבים דחופים כמו אמבולנסים וצוותים רפואיים.

עם זאת, מדד ה-Precision בקטגוריה זו בכל המודלים בסביבות 0.60-0.57 מה שמעיד על כמות מסוימת של התראות שווא. כלומר, המודלים חזו מקרים כפציעה גם כשאין פציעה בפועל. תופעה זו צפויה במודלים שמעדיפים רגישות (Recall) גבוהה, במיוחד כשמטרת העל היא לא לפספס אף פצוע, גם במחיר של הקצאת יתר של משאבים.

מדד ה-F1-Score, שמשקף את האיזון בין Recall ל-Precision, מדגיש את יתרונותיו של מודל CatBoost, שהשיג ציון גבוה של 0.73 תוצאה המצביעה על איזון איכותי בין זיהוי נכון של פצועים לבין צמצום התראות שווא ככל הניתן.

קטגוריית "אין פציעה" - No Injury Class (גרף ימני)

עבור קטגוריית "אין פציעה", כל המודלים הציגו Precision גבוה מאוד (0.98-0.99), מה שמעיד על כך שכאשר המודל קובע שלא הייתה פציעה, הוא כמעט תמיד צודק. זהו יתרון תפעולי משמעותי, שכן הוא מפחית הקצאת משאבים מיותרת למקרים לא דחופים, ומאפשר ניהול יעיל של כוח האדם והציוד בשטח.

מדדי ה-Recall בקטגוריה זו בטווח 0.84 ל-0.86, מצביעים על כך שבכ-14%-16% מהמקרים שהיו בפועל "אין פציעה", המודלים חזו בטעות כ-"יש פציעה". מדובר בתוצאה צפויה, הנובעת מהעדפה מודעת לרגישות גבוהה בקטגוריית "יש פציעה", גם במחיר של זיהוי יתר. מדובר ב-trade-off מכוון, שבו המודל מעדיף להתריע יותר, מאשר לפספס פצוע אמיתי. גישה שנקבעה מראש בהתאם ליעדים העסקיים: עדיף להפעיל משאבים לחינם מאשר לפספס מקרה פצוע בפועל.

מדדי ה-F1 הגבוהים (0.91-0.92) עבור קטגוריה זו מעידים על יציבות כללית טובה מאוד של המודלים. כל המודלים הציגו תוצאות מרשימות במחלקת "אין פציעה", הפגינו איזון טוב בין זיהוי מקרים אמיתיים (recall) לבין הימנעות מטעויות (precision).

מסקנה:

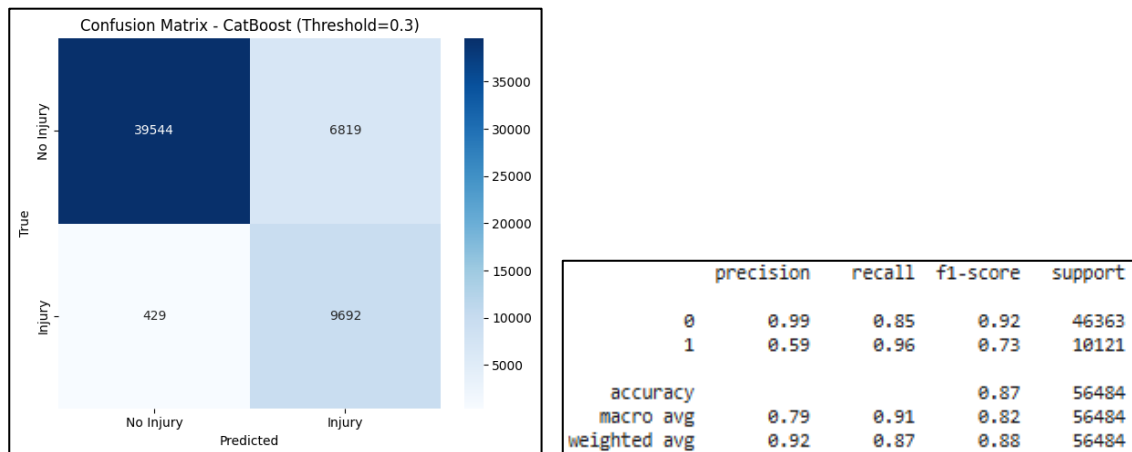
המודלים CatBoost ו-LightGBM הציגו ביצועים דומים, עם Recall גבוה לזיהוי פצועים (0.96 ו-0.95 בהתאמה), מה שמעיד על יכולת מרשימה לזהות תאונות שבהן יש פציעה, יעד קריטי בפרויקט. במקביל, בקטגוריית "אין פציעה", שניהם שמרו על Precision גבוה מאוד (0.99), מה שמפחית התראות שווא ואינו מבזבז משאבים על מקרים שאינם דורשים טיפול. מבין המודלים שנבחנו בחרנו במודל CatBoost כמודל הסופי בזכות שילוב של ביצועים טובים, איזון טוב בין Recall ל-Precision והתאמה טבעית לעבודה עם משתנים קטגוריאליים, יתרון שהפחית צורך בהמרות נתונים ותרם ליציבות ויעילות בפועל.

דירוג המודלים לפי התאמתם למטרות העסקיות

1. CatBoost (חיזוי בינארי) - נמצא כמודל המתאים ביותר לצרכי הפרויקט בזכות שילוב בין ביצועים גבוהים, יציבות תפעולית, והתמודדות מיטבית עם נתונים קטגוריאליים ללא צורך בהמרות. הציג Recall גבוה לצד רמת דיוק מספקת, מה שמאפשר זיהוי מירבי של פצועים תוך שמירה על איזון בתפעול.
2. LightGBM (חיזוי בינארי) - הציג ביצועים דומים מאוד ל-CatBoost, עם Recall גבוה ויציבות טובה. עם זאת, דרש טיפול מקדים במשתנים קטגוריאליים, מה שהוסיף מורכבות לשלב ההכנה.
3. XGBoost (חיזוי בינארי) - סיפק את ה-Recall הגבוה ביותר, אך המחיר היה ירידה ב-Precision שהובילה לריבוי התראות שווא, אתגר משמעותי בהקצאת משאבים בשטח.
4. Random Forest (חיזוי בינארי) - הציג ביצועים טובים אך נחותים יחסית במונחי Recall, מה שהוביל לפספוס פציעות בתדירות גבוהה יותר בהשוואה למודלים המובילים.



להלן התמקדות בדוח הביצועים המלא של המודל הנבחר CatBoost בחיזוי בינארי (יש פציעה / אין פציעה):



המודל שבחרנו: CatBoost הראה ביצועים מרשימים במונחים של Precision, Recall ו-F1-Score, בעיקר בכל הנוגע לזיהוי נכון של מקרי פציעה. נסקור את התוצאות המרכזיות וננתח את משמעותן:

קטגוריית "יש פציעה" (Injury)

Recall (0.96): המודל מזהה 96% מכלל מקרי הפציעה בפועל (9,692 מתוך 10,121). זהו הישג מרכזי, שכן הוא מבטיח שמרבית הפצועים לא יפספסו זיהוי.
Precision (0.59): כ-41% מהמקרים שחזינו כ"פציעה" התבררו בפועל כ"לא פציעה". תופעה זו צפויה ומכוונת לאור הבחירה במודל עם רגישות גבוהה, גם במחיר של יותר התראות שווא.
F1-Score (0.73): מצביע על איזון טוב בין רגישות גבוהה לבין שמירה על דיוק סביר בזיהוי פצועים.
משמעות עסקית: בחירה ברגישות גבוהה (Recall) היא אסטרטגית, מתוך הבנה שעדיף להפעיל משאבים מיותרים מאשר לפספס טיפול בפצוע אמיתי.

קטגוריית "אין פציעה" (No Injury)

Precision (0.99): כאשר המערכת חוזה שאין פציעה, היא כמעט תמיד צודקת (39,544 מתוך 39,973). נתון זה חשוב ליעילות תפעולית, שכן הוא מצמצם הקצאת משאבים לאירועים מיותרים.
Recall (0.85): כ-15% מהמקרים שבפועל לא הייתה בהם פציעה סווגו בטעות כ"פציעה" (False Positives).
F1-Score (0.92): איזון מצוין בין זיהוי נכון של מקרי "אין פציעה" לבין שמירה על שיעור שגיאות נמוך.

מדדים כלליים נוספים:

Accuracy (דיוק כללי): 0.87, משקף את אחוז החיזויים הנכונים מכלל המקרים. למרות שמדובר בערך גבוה, הוא פחות משמעותי במצב של חוסר איזון בין המחלקות, כפי שקיים בנתונים שלנו.

Macro Avg: Recall ממוצע של 0.91, Precision ממוצע של 0.79, ו-F1-Score ממוצע של 0.82, המייצגים את הביצועים הממוצעים של המודל בשתי הקטגוריות באופן שווה, ללא תלות בגודל כל מחלקה. מדד זה מראה שביצועי המודל מאוזנים גם אם בוחנים את שתי הקטגוריות במשקל שווה.

Weighted Avg: Recall של 0.87, Precision של 0.92, ו-F1-Score של 0.88. בניגוד לממוצע המקרו, כאן כל קטגוריה נשקלת לפי שכיחותה בדאטה. מאחר וקטגוריית "אין פציעה" נפוצה בהרבה, מדדים אלו מטים כלפי ביצועי המודל בה. זהו מדד המשקף בצורה טובה את הדיוק הכולל של המערכת בהתחשב בחלוקת הנתונים בפועל.

מטריצת הבלבול מחזקת את התמונה הזו:

- True Positives (TP) - 9,692 תאונות עם פציעה שזוהו נכון.
- False Negatives (FN) - 429 תאונות עם פציעה שלא זוהו (פספוס), שיעור נמוך של 4.2% ביחס לגודל המדגם, המעיד על עמידה ביעד של מניעת פספוס פצועים ככל הניתן.
- True Negatives (TN) - 39,544 תאונות ללא פציעה שזוהו נכון.
- False Positives (FP) - 6,819 תאונות שזוהו כפציעה למרות שלא הייתה, משקפים את המחיר של בחירה ברגישות גבוהה.



קישור התוצאות למטרות העסקיות

התוצאות מראות שהמודל CatBoost מיישם בהצלחה את היעד העסקי העיקרי שהוגדר בפרויקט- שיפור תגובת שירותי החירום והפחתת פספוס של פצועים.

- לטווח הקצר, שיעור ה-Recall הגבוה בקטגוריית הפציעות מבטיח איתור רוב הפצועים, דבר המאפשר תגובה מהירה והקצאת משאבים נכונה לאירועים הדורשים טיפול רפואי.
- לטווח הארוך, המודל, בשילוב עם כלים נוספים (כגון מפת חום של אזורי תאונות), יכול לתרום לתיעודף השקעות בתשתיות וחיזוק האכיפה באזורים מסוכנים.

מגבלות שזוהו במהלך ההערכה

במהלך שלב ההערכה (Evaluation) זוהו מספר מגבלות מהותיות בביצועי המודלים בגישה הבינארית כמו כן במודל הנבחר וביכולת היישום שלו בסביבה מבצעית. מגבלות אלו משפיעות הן על הדיוק המתקבל והן על היכולת של המערכת לספק מענה מלא ליעדים העסקיים שהוגדרו, בטווח הקצר של שיפור תגובת שירותי החירום והקצאת משאבים בזמן אמת, ובטווח הארוך של זיהוי מוקדי סיכון ותיעודף השקעות תשתית.

1. חוסר איזון בנתונים- חלוקה לא אחידה בין קטגוריות רמות הפציעה, ובעיקר שיעור נמוך מאוד של פציעות חמורות וקטלניות, הובילה לקושי בלמידה מדויקת של דפוסים בקטגוריות אלו. מצב זה פגע ביכולת המודל לייצר תחזיות אמינות במצב רב-קטגורי והיווה אחד הגורמים למעבר לחיזוי בינארי. מגבלה זו פוגעת במטרה לטווח הארוך של שיפור תשתיות ומניעת תאונות מקטגוריית פציעות חמורות.
2. ריבוי התראות שווא (False Positives)- מדד ה-Precision בקטגוריית "יש פציעה" מצביע על כך שחלק משמעותי מהאירועים שסווגו כפציעה אינם פציעות בפועל. מצב זה מוביל להקצאת משאבים מיותרת לשירותי החירום ומחייב בחינה של איזון מחדש בין רגישות (Recall) לבין דיוק (Precision). מגבלה זו פוגעת במטרה לטווח הקצר של אופטימיזציה בהקצאת משאבים בשטח.
3. מעבר לחיזוי בינארי והשלכותיו- ההחלטה לעבור למודל בינארי התקבלה מתוך מטרה למקסם את ה-Recall ולאתר את מירב מקרי הפציעה. עם זאת, צעד זה הביא למספר השלכות תפעוליות מהותיות:
 - מענה חלקי לשירותי החירום - המודל אינו מספק הבחנה בין דרגות פציעה שונות, ולכן אינו מאפשר לתעדף את רמת התגובה (למשל, טיפול נמרץ לעומת טיפול קל). מגבלה זו פוגעת במטרה לטווח הקצר של קבלת החלטות מדויקת בשטח.
 - פגיעה ביכולת תיעודף השקעות תשתית - היעדר הבחנה בין דרגות פציעה מגביל את היכולת לזהות מוקדי סיכון חמורים במיוחד, שעליהם יש להתמקד בפעולות מניעה ותכנון תשתיתי. מגבלה זו פוגעת במטרה לטווח הארוך של שיפור תשתיות ומניעת תאונות חמורות.

מענה לשאלות עסקיות:

לאורך הפרויקט עמדנו ברוב היעדים העסקיים שהוגדרו בשלב הייזום. המודל שפיתחנו מספק תחזית מדויקת לגבי עצם הימצאות פציעה בתאונה, ובכך מאפשר שיפור בהקצאת המשאבים של שירותי החירום בזמן אמת, הפחתת זמני תגובה, וזיהוי אזורים בסיכון גבוה, בעיקר באמצעות ניתוח תבניות והצגת מפת חום גאוגרפית. מענה זה נותן בסיס להחלטות אסטרטגיות מצד רשויות התחבורה, במטרה לשפר תשתיות באזורים מועדים לפרענות, וכן תומך במיקוד מאמצים של גופי אכיפה.

עם זאת, מאחר שבחרנו בגישת חיזוי בינארית (פציעה / אין פציעה), ולא חיזוי של רמות חומרת הפציעה, לא התאפשר מענה ישיר לשאלות עסקיות שדרשו הבחנה בין פציעות קלות, חמורות וקטלניות. בכך נפגעת היכולת לתעדף טיפול בשטח לפי דרגת החומרה.

לסיכום, הפרויקט הצליח לספק מענה איכותי ומדויק לרוב השאלות העסקיות המרכזיות שנקבעו בשלב הייזום, במיוחד בכל הנוגע לשיפור תגובת שירותי החירום, תיעודף משאבים, וזיהוי אזורים בסיכון גבוה. יחד עם זאת, ההחלטה להתמקד בחיזוי בינארי הביאה לתוצר ישים ומעשי אך השאירה מקום להרחבות עתידיות בדגש על הבחנה בין דרגות חומרה לצרכים אסטרטגיים ארוכי טווח של קובעי מדיניות, גופי ביטוח ורשויות תחבורה.

סיכום

למרות האתגרים המהותיים שבהם נתקלנו, ובראשם חוסר האיזון המשמעותי בין קטגוריות רמות הפציעה והקושי בזיהוי אמיין של פציעות חמורות, תהליך ההערכה הראה כי מודל ה-CatBoost, שנבחר לאחר השוואה למודלים נוספים, מספק ביצועים גבוהים ויציבים העומדים הן בקריטריונים הטכניים והן ביעדים העסקיים של הפרויקט. המודל השיג Recall מרשים של 0.96 בקטגוריית "יש פציעה", המבטיח איתור מרבי של פצועים בזמן אמת, לצד Precision גבוה של 0.99 בקטגוריית "אין פציעה", המאפשר הפחתת הקצאת משאבים מיותרת ושמירה על יעילות תפעולית. יתרונו הבולט ביכולת עבודה ישירה עם משתנים קטגוריאליים אפשר תהליך פיתוח יעיל והפחית את הצורך בהמרות נתונים מורכבות. בחירה מודעת בגישת החיזוי הבינארי, לאחר שגישות אחרות כגון חיזוי רב-קטגורי וחיזוי רב-שלב הניבו תוצאות פחות מספקות, הבטיחה מיקוד ביעד המרכזי של המערכת: זיהוי אמיין ומדויק של מקרי פציעה. שילוב של ביצועים טכניים גבוהים, יעילות תפעולית והתאמה לדרישות המבצעיות מציב את מודל ה-CatBoost כבסיס האופטימלי ליישום המערכת וכמרכיב מרכזי בהמשך פיתוחה ושכלולה לטווח הקצר והארוך.



2. סקירה של תהליך העבודה

במהלך הפרויקט יישמנו תהליך מקיף ומעמיק של חקירה, ניסוי וטעייה, אשר כלל ניתוחים חוזרים, התאמות מתמשכות והתמודדות עם אתגרים מהותיים הן בצד הנתונים והן בצד המידול. אחד האתגרים המרכזיים היה איכות הנתונים, ובפרט עמודת המטרה, שסבלה מחוסר איזון חמור בין קטגוריות חומרת הפגיעה, כאשר מקרי הפגיעה החמורה והקטלנית הופיעו בשכיחות נמוכה במיוחד ביחס לקטגוריות הרוב. מצב זה יצר קושי בזיהוי דפוסים בקטגוריות הנדירות והטיית המודלים לכיוון הקטגוריות השכיחות. לכך הצטרפה מורכבות נוספת של ערכים חסרים, אי-אחידות בנתונים, שימוש בקיצורים ושגיאות כתיב.

כדי להתמודד עם אתגרים אלו, יישמנו תהליך ניקוי וסטנדרטיזציה יסודי, ששילב בין טיפול ידני לבין אוטומציה: המרת ערכים באמצעות כללים מוגדרים, איחוד קטגוריות נדירות, השלמת נתונים חסרים בגישות מותאמות, ושימוש ב-fuzzy matching לתיקון ערכים לא עקביים. בנוסף, מאחר שחלק מהעמודות הכילו נתוני מיקום עם אלפי ערכים ייחודיים, יישמנו שיטת קידוד מרחבי באמצעות H3- אשר אפשרה לקבץ מיקומים לרמות דיוק שונות, להפחית מורכבות חישובית, וליצור תשתית לניתוח גיאוגרפי ויזואלי באמצעות מפות חום, בעלת ערך לטווח הארוך עבור גורמי חירום ותשתיות.

בשלב המידול בחנו מגוון גישות: החל מחיזוי רב-קטגורי מלא (חמש רמות חומרה), דרך חיזוי בשלוש קטגוריות מאוחדות ומודלים רב שלביים עם חיזוי הדרגתי. עם זאת, מרבית הגישות הרב קטגוריות לא עמדו בדרישות הדיוק והיציבות, בעיקר בשל האתגר בזיהוי קטגוריות נדירות. מתוך הצורך לספק פתרון אמין, יציב ויישומי, בחרנו בגישת חיזוי בינארית (פגיעה / אין פגיעה), שהתמקדה בשאלה הקריטית בזמן אמת, האם נדרש תגבור כוחות חירום. גישה זו הובילה לעלייה מובהקת ב-Recall, לצמצום פספוסים פגיעות ולשמירה על יציבות טכנית.

מודל CatBoost נבחר כמודל הסופי, הודות ליכולתו לעבד משתנים קטגוריאליים באופן טבעי, ללא צורך בהמרות מורכבות, תוך שמירה על מידע חיוני ושיפור יעילות ההרצה. תהליך זה הדגיש בפנינו תובנה מרכזית: הצלחת פרויקט כריית נתונים אינה נמדדת רק במדדי ביצועים טכניים, אלא גם ביכולת לתמוך במטרות העסקיות בפועל. המודל שנבחר סיפק מענה ישיר לאחד הצרכים המרכזיים של הגורמים בזירת התאונה- קבלת החלטות מהירה, מבוססת נתונים, ואפקטיבית בשטח.

לו היה עומד לרשותנו זמן נוסף, היינו בוחנות שיטות איזון מתקדמות נוספות, מערכי אימון חלופיים ושילוב מקורות נתונים חיצוניים, כגון גיל הנהג או עומסי תנועה בזמן אמת, לשיפור דיוק המודל.

בסיכומו של דבר, תהליך העבודה בפרויקט זה חיזק את היכולות הטכניות והתהליכיות שלנו, והעמיק את ההבנה בחיבור שבין ניתוח נתונים למטרות מבצעיות, תוך יכולת להנגיש ממצאים בצורה ויזואלית ומובנת לגורמים לא טכניים באמצעות גרפים, מטריצות בלבול ומפות חום.